Технический разбор PhAIL: всё, что нужно знать чтобы защитить статью

Этот документ --- спутник к статье. Идея: пройти пошагово от "зачем всё это" до "что отвечать рецензенту", объясняя каждый технический термин в момент его появления. Если рецензент спросит "а что такое X?" --- ответ должен быть здесь.

Содержание

1 Зачем всё это: проблема с бинарной долей успехов **1**

2 Случайная величина T и её CDF **2**

3 Kaplan-Meier: как оценивать CDF при наличии цензурирования **2**

4 Скаляры из CDF: что мы публикуем **4**

5 Доверительные интервалы: episode-clustered bootstrap **4**

6 От описания к ранжированию: зачем нужны отдельные тесты **5**

7 Logrank: классический тест на равенство CDF **6**

8 KS: Kolmogorov-Smirnov, наш основной тест **6**

9 Поправка на множественные сравнения: Bonferroni **7**

10 Анализ мощности: откуда берётся 600--1500 парных rollout'ов **8**

11 Эксперимент с подвыборками: как мы строим графики мощности **9**

12 Logrank vs KS на наших данных: согласуются ли? **10**

13 Полный workflow ranking-утверждений **11**

14 Возможные вопросы рецензентов **11**

1. Зачем всё это: проблема с бинарной долей успехов

Стандартная практика в VLA-статьях: "наша модель завершает 70% эпизодов за τ секунд". Это прокси надёжности --- говорит, насколько модель устойчива. Но:

1. **Не учитывает скорость работы.** 90% за 30 с и 90% за 300 с --- абсолютно разные политики, но бинарная доля одинакова.
2. **Зависит от выбора τ.** На разных τ ранжирование моделей может меняться (наша Таблица 3 показывает: $F(30s)$ и $F(60s)$ дают разные top-1).
3. **Нечувствителен к форме распределения.** Политика "или быстро или никогда" и политика "всегда среднеспешная" могут иметь одинаковый $F(\tau)$.

Решение: измерять *распределение* времени до успеха T целиком, а не только его значение в одной точке.

2. Случайная величина T и её CDF

Определение T. T --- время от начала операции до её успешного завершения. "Операция" --- это перемещение одного предмета из исходного контейнера в целевой. Один rollout (запуск модели на эпизоде) содержит несколько операций (батарейки --- 10+, ножницы --- 1).

Три класса исходов операции.

1. **Успех**: модель положила предмет в целевой контейнер. T --- время от старта до этого момента, событие $E = 1$.
2. **Правоцензурированный** (right-censored): эпизод закончился по таймауту (30 с/предмет, или оператор остановил), модель ещё работала, но предмет не положен. Знаем $T > T_{\text{tail}}$, но не само T. Событие $E = 0$.
3. **Жёсткий провал** (hard failure): предмет уронен за пределы рабочего пространства, или сработала аварийная остановка. Операция *не может* завершиться никогда. Записываем как $T = \infty$, $E = 1$ ("событие-призрак", ghost event).

CDF. $F(t) = P(T \leq t)$ --- доля операций, завершённых к моменту t. Из определения: $F(0) = 0$, F монотонно растёт, $F(\infty) \leq 1$ (асимптота ниже 1 = доля жёстких провалов).

Почему CDF, а не функция выживания $S(t) = 1 - F(t)$. Эквивалентно с математической точки зрения. CDF интуитивнее для не-survival-аудитории: "доля завершённых" читается напрямую с графика. Функция выживания --- стандарт в медицине, но мы пишем для ML-сообщества.

3. Kaplan-Meier: как оценивать CDF при наличии цензурирования

Почему не просто эмпирическая CDF. Эмпирическая CDF $\hat{F}(t) = \frac{1}{n}\sum_i \mathbb{1}[T_i \leq t]$ требует знания T для всех наблюдений. У нас часть --- правоцензурированные ($T > T_{\text{tail}}$, точное значение неизвестно). Их нельзя ни выбросить (систематический сдвиг к коротким временам), ни считать как $T = T_{\text{tail}}$ (заниженная оценка).

Оценка Kaplan-Meier (1958). Оценивает $S(t) = 1 - F(t)$ как произведение условных вероятностей "выжить через момент t_i":

$$\hat{S}(t) = \prod_{t_i \le t} \left(1 - \frac{d_i}{n_i}\right)$$

где t_i --- моменты событий (успехов), d_i --- число успехов в момент t_i, n_i --- размер выборки-в-риске (тех, кто ещё не "вышел" до t_i). Цензурированные наблюдения остаются в n_i до момента цензурирования, потом выпадают --- без подделки события.

Дисперсия по Greenwood. Оценка дисперсии Kaplan-Meier-оценки $\hat{S}(t)$:

$$\widehat{\mathrm{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{t_i \le t} \frac{d_i}{n_i(n_i - d_i)}$$

Откуда формула. Поскольку $\hat{S}(t) = \prod(1 - d_i/n_i)$, логарифм превращается в сумму:

$$\log \hat{S}(t) = \sum_{t_i \le t} \log\left(1 - \frac{d_i}{n_i}\right).$$

Каждое слагаемое --- условная вероятность "выжить через момент t_i", биномиальная по природе с дисперсией $d_i/(n_i(n_i - d_i))$. Сумма (под предположением независимости наблюдений) даёт $\mathrm{Var}(\log \hat{S})$. Возвращаемся к $\hat{S}$ через delta-метод --- получаем формулу выше.

Что она даёт. Для каждого момента t --- стандартную ошибку $\hat{S}(t)$. Из неё строится поточечный 95% доверительный интервал на $S(t)$ (или эквивалентно $F(t) = 1 - S(t)$).

Log-log преобразование. Если строить наивный 95% CI как $\hat{S}(t) \pm 1.96 \cdot \mathrm{SE}$ --- при низких n интервал может выходить за $[0, 1]$. Например, $\hat{S} = 0.05$, $\mathrm{SE} = 0.04 \Rightarrow$ нижняя граница -0.03. Это бессмысленно для вероятности.

Решение. Преобразование $g(S) = \log(-\log S)$ отображает $S \in (0, 1)$ в $\mathbb{R}$. Строим симметричный гауссовский CI в трансформированной шкале, потом возвращаемся обратно:

$$\mathrm{CI}_{95\%}(S(t)) = \hat{S}(t)^{\exp\left(\pm 1.96 \cdot \mathrm{SE}(\log(-\log \hat{S}(t)))\right)}$$

Гарантированно остаётся в $(0, 1)$ и асимптотически корректный. Полученный интервал *асимметричен*: при $\hat{S}$ близком к нулю или единице он шире со стороны, удалённой от границы --- ровно потому, что вблизи границы вероятность плотно "упирается".

Где Greenwood в нашей статье --- и где НЕ. Прямой ответ: **в главных таблицах и фигурах мы Greenwood не используем**. Все 95% CI в Таблицах 2--4 и Рисунках 1--5 построены через бутстрап по эпизодам.

Почему не Greenwood. Greenwood предполагает независимость наблюдений (операций). У нас операции внутри эпизода коррелированы --- общая сцена, освещение, состояние политики. Greenwood в этом случае дал бы искусственно узкие интервалы --- ту же проблему, что и стандартный бутстрап по операциям. Бутстрап по эпизодам корректно учитывает корреляцию.

Где упоминается. В §2.1 статьи: *"pointwise log-log intervals using the Greenwood variance estimator are equivalent and described in Kalbfleisch--Prentice"* --- то есть мы признаём Greenwood как канонический метод survival analysis, но используем бутстрап как более подходящий для нашего случая. Это покрывает рецензента, который скажет: "почему не стандартный Greenwood?" --- ответ: коррелированные наблюдения, см. §2.2.

Когда Greenwood и бутстрап эквивалентны. Если бы у нас был один эпизод = одна операция (как в медицинском survival, где пациент = одно событие), Greenwood и бутстрап по эпизодам дали бы практически одинаковые CI. Но у нас один эпизод = много операций (батарейки --- 10+), и эта внутри-эпизодная корреляция критична.

Призраки ($T = \infty$). Простое расширение: жёсткий провал добавляет дискретный скачок CDF в правом крае. Эквивалентно: для интегральных метрик (RMST) подставляем $T_{\text{ghost}} = \tau$ (потолок интегрирования). Жёсткий провал увеличивает RMST ровно на τ минус то время, которое политика потратила бы на эту операцию при успехе.

4. Скаляры из CDF: что мы публикуем

Все стандартные скаляры --- проекции F.

$$
\begin{aligned}
F(\tau) &= \text{доля успехов к моменту } \tau \\
\inf\{t : F(t) \geq 0.5\} &= \text{медианное время до успеха} \\
\int_0^\tau (1 - F(t))\, dt &= \text{RMST}(\tau) \text{ (restricted mean survival time)} \\
3600/E[T \mid T < \tau] &\propto 1/\text{RMST} = \text{UPH (units per hour)} \\
\text{RMST}(\tau)/(1 - F(\tau)) &= \text{MTBF/A (mean time between failures/assists)}
\end{aligned}
$$

HRT (Human-Relative Throughput) -- наш главный скаляр.

$$
\text{HRT}(m, o) = \frac{\text{RMST}_{\text{teleop},o}(\tau)}{\text{RMST}_{m,o}(\tau)}, \qquad \text{HRT}(m) = \frac{1}{|O|} \sum_{o \in O} \text{HRT}(m, o)
$$

Поячеечное отношение модели к телеоп-референсу, макро-усреднённое по объектам. Свойства:

- **Безразмерность**: можно сравнивать разнородные задачи.
- **Поячеечная нормализация**: трудный объект замедляет телеоп и модель пропорционально --- сложность объекта сокращается.
- $T = \infty$ **увеличивает знаменатель**: жёсткие провалы автоматически штрафуют HRT.
- **Макро vs микро**: макро-усреднение по объектам, чтобы один тяжёлый объект (мало эпизодов) не доминировал.

Почему $\tau = 240$ с в главной таблице. 30 с/предмет $\times$ 8 предметов в самой длинной задаче = 240 с --- естественный потолок эпизода в нашем протоколе. Цензурируем T при τ --- это "сколько модель потратила бы, если бы работала вечно (но мы не наблюдали)".

5. Доверительные интервалы: episode-clustered bootstrap

Зачем бутстрап. Хотим доверительный интервал на любой скаляр (RMST, HRT, $F(\tau)$). Аналитические формулы (Greenwood и т.п.) --- только для отдельных метрик и при предположениях независимости. Бутстрап --- универсальный непараметрический метод (Efron, 1979).

Идея бутстрапа. Многократно (B раз) ресэмплируем из наших данных с возвращением, считаем метрику на каждом ресэмпле, берём 2.5-й и 97.5-й перцентили --- это и есть 95% доверительный интервал.

Почему *по эпизодам кластеризованный*. Стандартный бутстрап --- ресэмпл по *наблюдениям* (т.е. по операциям). Но операции внутри одного эпизода *коррелированы* --- они делят:

- Состояние политики (после первой операции изменился контекст).
- Визуальные условия (та же сцена, освещение, камера).
- Стартовое состояние робота.

Если ресэмплировать по операциям, получаем *искусственно узкие* доверительные интервалы --- они занижают неопределённость, потому что не учитывают эту корреляцию. Эпизод --- естественный независимый блок (разные стартовые условия, независимые запуски).

Алгоритм.

1. Берём n эпизодов в группе.
2. Ресэмплируем n эпизодов с возвращением $\Rightarrow$ бутстрап-выборка.
3. Считаем метрику (RMST, $F(\tau)$, HRT) на этой выборке.
4. Повторяем $B = 1000$--2000 раз.
5. Перцентильный интервал: $[\text{quantile}_{2.5},\ \text{quantile}_{97.5}]$.

Парный бутстрап для сравнения двух политик. При сравнении модели A и модели B (или модели и телеопа) на одних объектах: ресэмплируем *пары* индексов, чтобы сохранить корреляцию между моделями. "Парные" в смысле "один и тот же эпизод-объект в обеих группах", что снижает дисперсию разностей.

6. От описания к ранжированию: зачем нужны отдельные тесты

Описание (что есть). "RMST модели $= 80$ с, 95% CI [70, 92]" --- описательная статистика. Не отвечает на вопрос "отличается ли это от другой модели?".

Наивная ошибка #1: "сравнить точки". "RMST $A = 80$, RMST $B = 85$, значит A лучше" --- игнорирует доверительный интервал. Если интервалы пересекаются, разница может быть шумом.

Наивная ошибка #2: "пересекаются ли интервалы". "CI $A = [70, 92]$, CI $B = [75, 95]$, они пересекаются $\Rightarrow$ нет разницы". *Неверно*: пересечение маргинальных интервалов не эквивалентно отсутствию разницы. Правильно сравнивать интервал на *разности* $A - B$, а не два отдельных интервала.

Что мы хотим. Формальный тест: "какова вероятность увидеть наблюдаемую разницу или больше при $H_0 : F_A = F_B$?". Это p-значение. Если $p < 0.05$ --- отвергаем H_0.

Двое таких тестов в нашей статье.

1. **Logrank** (раздел 7) --- классика survival analysis, контрольная проверка.
2. **Kolmogorov-Smirnov** (раздел 8) --- наш основной тест, более экономный по выборке.

7. Logrank: классический тест на равенство CDF

Тест на сравнение двух кривых выживаемости. Спрашивает: $H_0 : F_a = F_b$.

Механика.

1. Соберите все события (успехи) из обеих групп и упорядочьте по времени: $t_1 < t_2 < \cdots < t_K$.
2. В каждый момент события t_i посмотрите на *выборку-в-риске* --- операции, которые ещё не завершились к этому моменту в обеих группах. Пусть $n_{a,i}, n_{b,i}$ --- размер выборки-в-риске в группах, d_i --- общее число событий в момент t_i.
3. Под H_0 ожидаемое число событий из группы a пропорционально доле в выборке-в-риске:
$$E_{a,i} = d_i \cdot \frac{n_{a,i}}{n_{a,i} + n_{b,i}}$$
4. Сравните наблюдаемое с ожидаемым:
$$Z = \frac{\sum_i (O_{a,i} - E_{a,i})}{\sqrt{\sum_i V_i}} \sim \mathcal{N}(0, 1)$$
где V_i --- гипергеометрическая дисперсия в каждом моменте.
5. $Z^2 \sim \chi^2_1$ под H_0 --- это и есть logrank-статистика.

Интуиция. В каждый момент события спрашиваем: "если бы группы были одинаковыми, какая доля сегодняшних успехов должна быть из группы a?". Складываем расхождения. Систематический сдвиг $\Rightarrow$ статистика растёт.

Свойства.

1. Использует *всю кривую*, а не одно $F(\tau)$.
2. Нативно обрабатывает цензурирование.
3. Стандарт в медицинской survival analysis с 1966 г. (Mantel).

Слабое место. Logrank *предполагает пропорциональные риски* --- что отношение hazard-функций двух групп постоянно по времени. Если кривые *пересекаются* (crossover), logrank теряет мощность. На наших данных пересечений нет, но это известное ограничение, и KS этого не требует.

8. KS: Kolmogorov-Smirnov, наш основной тест

Статистика.
$$D = \sup_t \left| F_a(t) - F_b(t) \right|$$
максимальное вертикальное расстояние между двумя CDF.

Геометрия через P-P plot. Если параметрически отложить $\big(F_a(t), F_b(t)\big)$ при $t \in [0, \tau]$ --- получим P-P-кривую. Тогда:

- **AUC** (площадь под кривой) $= P(T_a < T_b)$ --- попарное стохастическое доминирование.
- **KS** $=$ максимальное вертикальное расстояние от кривой до диагонали.

Обе метрики читаются с одной картинки.

Что говорит и не говорит. KS отвечает "отличаются?" --- да или нет с p-значением. *Не говорит, какая модель быстрее*. Направление берём из RMST или знака $F_a(t^*) - F_b(t^*)$ в точке максимума. В статье публикуем оба: KS ("отличаются?") + RMST ("кто быстрее?").

Почему НЕ используем стандартное p-значение KS. Учебная асимптотика KS предполагает независимость наблюдений. У нас операции внутри эпизода коррелированы. Поэтому:

$$p\text{-значение KS} = \text{бутстрап с кластеризацией по эпизодам}$$

1. Объединяем эпизоды обеих групп в общий пул под H_0.
2. Многократно (200--2000) ресэмплируем целые эпизоды с возвращением, разбиваем случайно на две группы того же размера, считаем D^*.
3. p-значение $=$ доля бутстрапа, где $D^* \geq D_{\text{наблюдённое}}$.

Почему KS экономный по выборке. KS чувствителен к точке, где кривые расходятся максимально. RMST $= \int_0^\tau (1 - F(t))\, dt$ --- интегратор, размазывает информацию о расхождении по всему $[0, \tau]$. На пограничных парах KS детектирует разницу при $N = 20$, RMST и $F(60s)$ --- никогда при $N \leq 30$. Информация живёт в *том, где* кривые разделяются; интегратор её сглаживает, sup-норма её ловит.

9. Поправка на множественные сравнения: Bonferroni

Какие именно 6 гипотез. Для четырёх моделей $\binom{4}{2} = 6$ пар. Для каждой пары (a, b):

$$H_0^{(a,b)} : F_a = F_b \quad \text{против} \quad H_1^{(a,b)} : F_a \neq F_b.$$

Конкретно:

1. OpenPI $=$ GR00T
2. OpenPI $=$ ACT
3. OpenPI $=$ SmolVLA
4. GR00T $=$ ACT
5. GR00T $=$ SmolVLA
6. ACT $=$ SmolVLA

Зачем коррекция: семейная ошибка первого рода (FWER). При K независимых тестов на уровне $\alpha = 0.05$:

$$\text{FWER} = P(\text{хотя бы один ложно-положительный}) = 1 - (1 - \alpha)^K \approx K\alpha$$

При $K = 6$: FWER ≈ 0.26. То есть 26% шанс опубликовать ложно-значимое сравнение, даже если все модели одинаковы.

Bonferroni. Тестировать каждую гипотезу на уровне α/K. Эквивалентно: $p_{\text{Bonf}} = \min(K \cdot p_{\text{raw}},\ 1)$. Гарантирует FWER $\leq \alpha$ при любой структуре зависимости тестов.

Альтернативы и почему не они.

- **Без коррекции**: 26% шанс ложного срабатывания --- нечестно.
- **Holm step-down**: тоже контролирует FWER, чуть менее консервативен. На $K = 6$ выигрыш мал.
- **Benjamini-Hochberg (FDR)**: контролирует ожидаемую долю ложных открытий, не вероятность хотя бы одного. Для исследовательских анализов с тысячами тестов. Не для несущих ranking-утверждений в статье.

Наш контекст: 6 подтверждающих ranking-утверждений, каждое публикуется отдельно. Bonferroni --- правильный выбор.

Что выживает Bonferroni у нас.

- Все 3 пары vs SmolVLA: $p_{\text{Bonf}} < 10^{-14}$ --- железные $***$.
- GR00T vs ACT: $p_{\text{raw}} = 2.3{\cdot}10^{-3} \Rightarrow p_{\text{Bonf}} = 1.4{\cdot}10^{-2}$ --- выживает, $*$.
- OpenPI vs ACT: $p_{\text{raw}} = 1.1{\cdot}10^{-2} \Rightarrow p_{\text{Bonf}} = 6.7{\cdot}10^{-2}$ --- *не* выживает, пограничный.
- OpenPI vs GR00T: $p_{\text{raw}} = 0.45$ --- ни до, ни после.

Bonferroni "съел" OpenPI vs ACT --- без коррекции мы бы заявили значимость, после --- честно говорим маргинально. В этом и смысл коррекции.

10. Анализ мощности: откуда берётся 600--1500 парных rollout'ов

Мощность теста. Вероятность отвергнуть H_0, когда H_1 верна. Конвенция $1 - \beta = 0.8$ (80% мощность).

Тест McNemar (парный бинарный). Для пары моделей с парными бинарными исходами (успех/неудача) рассматриваются *несогласные пары* --- эпизоды, где одна модель преуспела, другая нет. Статистика:

$$\chi^2 = \frac{(b - c)^2}{b + c}$$

где b, c --- числа несогласных пар в обоих направлениях. Парность учитывает корреляцию через одинаковую сцену и объект --- чувствительность выше, чем у непарного теста.

Сколько парных rollout'ов нужно? Для детекции разницы в доле успехов $\Delta = 0.05$ (5 процентных пунктов) при мощности $= 0.8$, $\alpha = 0.05$, доле несогласных пар 0.2:

$$N \approx \frac{(z_{\alpha/2}\sqrt{2p_d} + z_{\beta}\sqrt{p_d - \Delta^2})^2}{\Delta^2} \approx 1280$$

где p_d --- доля несогласных пар. Диапазон 600--1500 --- при разных предположениях о p_d (от 0.1 до 0.3).

Связь с нашими данными. Сообщество работает на $N = 10$--20 на условие. McNemar говорит: для сравнений топ-VLA (5 п.п. разрыв) нужно 600--1500. Разрыв в 30--75×. Это и есть "two orders of magnitude under-budgeted" из абстракта.

Парный vs непарный тест.

- **Непарный**: две независимые группы выбираются случайно из своих популяций. Дисперсия выше, нужно больше N.
- **Парный**: две группы матчатся по релевантным факторам (объект, конфигурация, сцена). Снимает межусловную дисперсию, эффективно требует меньше N.

В PhAIL "парный" = "один и тот же объект, одна и та же конфигурация камеры/контейнера, разные модели в случайной чередующейся ротации". Каждая (модель, объект, конфигурация)-ячейка --- условие парности.

11. Эксперимент с подвыборками: как мы строим графики мощности

McNemar даёт аналитический ответ "сколько надо при бинарной метрике". Но для KS аналитики нет, и мы хотим напрямую сравнить четыре метрики ($F(30s)$, $F(60s)$, RMST, KS) на одних данных. Поэтому делаем *эмпирический эксперимент мощности*: симулируем, как часто каждая метрика даёт $p < 0.05$ при разных размерах выборки.

Что такое detection rate. Это эмпирическая мощность теста: при N эпизодах на (модель, объект)-ячейку --- какая доля экспериментов отвергнет $H_0 : F_a = F_b$? Если detection rate $= 0.8$ --- значит в 80% случаев тест бы поймал разницу. Конвенциональная цель: detection rate ≥ 0.8.

Что такое размер подвыборки N. У нас в датасете 30--45 эпизодов на ячейку. "Подвыборка N" = "а что было бы, если бы у нас было только N?". Тестируем $N \in \{5, 10, 15, 20, 25, 30\}$. $N = 5$ --- симулирует типичную VLA-статью; $N = 30$ --- ближе к нашему фактическому размеру.

Алгоритм для одной точки на графике. Зафиксируем пару моделей (например, GR00T vs ACT), метрику (например, KS) и $N = 20$.

1. **Внешний цикл --- 300 trials**. Каждый trial симулирует один "паралельный мир":
   - Для каждой (модель, объект)-ячейки берём подвыборку из $N = 20$ эпизодов с возвращением. Получаем 4 ячейки × 2 модели = 8 подвыборок по 20 эпизодов.
   - Считаем p-значение KS на этих подвыборках (см. внутренний цикл ниже).
2. **Внутренний цикл (внутри одного trial) --- бутстрап в 200 повторов**, чтобы получить p-значение KS:
   - Считаем наблюдаемую KS-статистику D_{obs} на подвыборках двух моделей.
   - 200 раз: объединяем подвыборки в общий пул под H_0, ресэмплируем целые эпизоды, разбиваем случайно на две группы того же размера, считаем D^*.
   - p = доля из 200, где $D^* \geq D_{\text{obs}}$.
3. **Detection rate** = доля из 300 внешних trials, где $p < 0.05$. Это и есть точка на графике для этой (пары, метрики, N).

Что получается. Для каждой пары моделей (6 пар) и каждой метрики (4 метрики) и каждого N (6 значений) $= 144$ точки. Складываем в кривые detection rate vs N --- по одной кривой на каждую (пара, метрика).

Как читать график (Рисунок 4 в статье).

- Ось x: N (5--30).
- Ось y: detection rate (0--1).
- Кривая на $y = 1$ означает "тест всегда детектирует разницу" --- эффект огромный.
- Кривая около $y = 0.05$ --- детектирует с шумом (примерно как от случайности).
- Пересечение $y = 0.8$ --- конвенциональная цель 80% мощности.

Что мы видим на трёх режимах.

- **Насыщенные пары** (любая модель vs SmolVLA): все четыре метрики выходят на $y = 1$ уже при $N \leq 10$. Эффект огромный, любой тест поймает.
- **Близкие пары** (top-3 модели между собой): только KS поднимается. На GR00T vs ACT KS пересекает 0.8 при $N = 20$. Остальные метрики остаются на полу (< 0.30 при $N = 30$).
- **Истинная ничья** (OpenPI vs GR00T): даже KS не достигает 0.8 при $N = 30$ (поднимается до 0.61). Остальные метрики около 0.05 --- неотличимо от случайности.

Параметры эксперимента и почему именно такие.

- **300 внешних trials** --- даёт Monte-Carlo стандартную ошибку $< 3\%$ на detection rate (в худшем случае при rate $= 0.5$).
- **200 внутренних повторов** --- разрешение p-значения до 0.005. При большем числе бутстрап-повторов p-значения становились бы точнее, но за рамками 0.05-границы это не меняет detection rate.
- $\tau = 120$ **с** для эксперимента (вместо 240 с в главной таблице) --- сужает диапазон интегрирования RMST до области, где модели реально работают, чтобы дать RMST максимально честный шанс. Если бы RMST провалила тест при $\tau = 120$ с, не помогло бы и $\tau = 240$ с.

Связь с реальным N. Наши per-cell $N \approx 30$--45. Подвыборка $N = 30$ --- близко к полному размеру (поэтому KS detection rate при $N = 30$ --- хорошая аппроксимация настоящего p-значения KS на полных данных). Подвыборка $N = 5$ --- симулирует типичную VLA-статью. Разница между двумя крайностями --- наша headline-картинка о том, как сильно N влияет на разрешающую способность.

12. Logrank vs KS на наших данных: согласуются ли?

Оба теста на одну и ту же H_0, разные статистики. Если *не согласуются* --- сигнал проблемы. Если согласуются --- ranking-утверждение надёжно.

Пара	logrank p_{raw}	KS det. rate (N=30)	Согласие
OpenPI vs SmolVLA	$< 10^{-15}$	1.00	оба ***
GR00T vs SmolVLA	$< 10^{-15}$	1.00	оба ***
ACT vs SmolVLA	$3.3 \cdot 10^{-16}$	1.00	оба ***
GR00T vs ACT	$2.3 \cdot 10^{-3}$	0.95	оба значимо
OpenPI vs ACT	$1.1 \cdot 10^{-2}$	0.75	оба пограничные
OpenPI vs GR00T	0.45	0.61	оба не значимо

Согласие на всех 6 парах. Качественный рейтинг совпадает. KS более чувствителен на близких парах (отсюда выбор как основной), logrank как контрольная проверка (стандарт литературы).

13. Полный workflow ranking-утверждений

1. **Объединённая CDF на каждую модель** (по 4 объектам) с бутстрапом по эпизодам для доверительных интервалов.
2. **Скаляр для отчёта**: RMST или HRT $\pm$ 95% CI. Не используется для решения "отличаются ли модели".
3. **Тест для ранжирования**: попарный KS на макро-CDF + бутстрап по эпизодам, 6 тестов, поправка Bonferroni.
4. **Контрольная проверка**: попарный logrank, тоже Bonferroni, 6 тестов. Сравниваем согласие.
5. **Направление**: знак ΔRMST --- какая модель быстрее.

KS отвечает на "отличаются?", RMST/HRT --- на "кто быстрее", Bonferroni --- на "сколько ложных срабатываний мы публикуем". Это и есть "two-jobs framing" статьи: скаляр для отчёта, тест для ранжирования.

14. Возможные вопросы рецензентов

"Почему не использовали AUC как главный скаляр? Он же даёт top-1 для ACT." AUC $= P(T_{\text{model}} < T_{\text{teleop}})$. На наших данных телеоп $\sim 7\times$ быстрее, поэтому AUC доминируется коротковременной областью --- модель с пиком "быстро-когда-получается" (ACT) выигрывает там, даже если её steady-state хуже. Это свойство референса, не самого AUC. RMST интегрирует по всему $[0, \tau]$ равномерно. Оба корректны; мы выбрали HRT (через RMST) потому что (а) совмещает надёжность и скорость через $T = \infty$, (б) UPH-эквивалент, ближе к operator-практике. *Главное --- само это разногласие и есть наш эмпирический вклад.*

"$N \approx 35$ маловато даже для вашего теста." Согласны: на ближайшей паре (OpenPI vs GR00T) даже KS не достигает 80% мощности при $N = 30$. Статья это явно говорит и предлагает $N = 600$--1500 как требуемый бюджет. Но ключевое утверждение не "мы разрешили все пары" --- ключевое в том, что (а) GR00T-vs-ACT мы разрешили при $N = 20$, (б) бинарные метрики не разрешат этого ни при каком практичном N. "The choice of test, not the choice of N, determines what is resolvable."

"Почему бутстрап по эпизодам, а не стандартный?" Операции внутри эпизода коррелированы (общее состояние политики, сцена, освещение). Стандартный бутстрап по операциям даёт искусственно узкие доверительные интервалы. Эпизод --- естественный независимый блок. Это известная техника (Efron-Tibshirani для кластеризованных данных).

"Почему KS, а не Anderson-Darling или Cramer-von Mises?" Anderson-Darling сильнее весит хвосты --- хорошо, когда нас интересуют события на хвостах, у нас не тот случай. Cramer-von Mises использует L_2-норму, KS --- L_∞. Различие на наших данных в пределах шума, но KS --- стандарт, легче объяснить рецензенту, и его геометрия (максимальное расстояние на P-P-plot) делает его читаемым с рисунка.

"Откуда 600--1500 парных rollout'ов? Покажите расчёт." Формула McNemar: $N \approx (z_{\alpha/2}\sqrt{2p_d} + z_\beta\sqrt{p_d - \Delta^2})^2/\Delta^2$ при $\Delta = 0.05$ (5 п.п.), мощность 0.8, $\alpha = 0.05$. Диапазон 600--1500 $=$ при $p_d \in [0.1, 0.3]$. Полный вывод в Приложении F статьи.

"Почему дефолтные рецепты файн-тюнинга? Это унижает модели." Намеренно. Оптимизация под каждую модель сместила бы ранжирование и сделала бы статью про конкретные рецепты, а не про методологию. Методология --- вклад; ранжирование --- иллюстрация. Статья это явно говорит ("the contribution is methodological").

"Почему 4 объекта? Почему именно эти 4?" Деревянные ложки (твёрдые, удлинённые), полотенца (деформируемые), ножницы (шарнирные, металлические), батарейки (мелкие, твёрдые) --- разные физические режимы. 4 --- компромисс между покрытием и бюджетом на аннотацию и телеоперференс. Бенчмарк спроектирован расти --- следующие задачи (вставка, мелкая сборка) commited в Future Work.

"Как вы знаете, что аннотации надёжны?" Двойной поток: высокотировые краудсорс-аннотаторы (Толока) + автоматический пайплайн детекции. Краудсорс --- золотой стандарт, автоматический оценивается против него на каждом эпизоде. Расхождения публикуются и используются для уточнения автоматического, не наоборот. Оба потока публикуются.

"В Приложении C GR00T теряет 22 п.п. при противоположной стороне камеры. Это разве не главная проблема?" Это *и есть* вторая методологическая claim: средовые конфаунды могут двигать ранжирование сильнее, чем разрывы между моделями. Поэтому same-fixture рандомизированная ротация со слепым оператором --- предусловие для всего остального. PhAIL логирует конфигурацию с каждым эпизодом --- конфаунд виден аналитику, а не растворяется в шуме.

"Почему single-blind, а не double-blind?" ED-track NeurIPS позволяет single-blind *только* для dataset-centered подач. Наша статья --- бенчмарк/датасет, поэтому подаём single-blind с открытым именем автора и аффилиацией. Это *требование* call-a, не прихоть.

"Что если рецензент скажет: "just use AUC, it's a single number"?" Это и есть главный эмпирический вклад: "одно число" зависит от выбора. AUC, RMST, $F(30s)$ --- три principled scalars, три разных top-1. На наших данных это *доказано* (Таблица 3, §5). Если нет CDF, одно число может ввести в заблуждение; если есть CDF, выбор скаляра --- осознанный выбор приоритета представления.